

機器學習十大核心演算法 深度研讀與實務應用報告

技術架構、數學原理、圖解與全場景案例分析

研究單位：高級人工智慧架構與數據科學實驗室

報告編撰：技術專家團隊 / 研讀專案小組

發布日期：2026 年 6 月

目錄

1. 引言：現代機器學習理論範式
2. 第一部分：監督式學習 - 回歸模型
 - 1. 線性回歸 (Linear Regression)
3. 第二部分：監督式學習 - 分類模型
 - 2. 邏輯回歸 (Logistic Regression)
 - 3. 支持向量機 (Support Vector Machines, SVM)
 - 4. 單純貝氏分類器 (Naive Bayes Classifier)
 - 5. K-最近鄰演算法 (K-Nearest Neighbors, KNN)
4. 第三部分：樹狀模型與整合式學習
 - 6. 決策樹 (Decision Trees)
 - 7. 隨機森林 (Random Forest)
 - 8. 梯度提升架構 (Gradient Boosting Models)
5. 第四部分：非監督式學習
 - 9. K-Means 分群演算法 (K-Means Clustering)
 - 10. 主成分分析 (Principal Component Analysis, PCA)
6. 第五部分：演算法核心效能與適用場景綜合評估

1. 引言：現代機器學習理論範式

在當今數據驅動的科技浪潮中，機器學習（Machine Learning, ML）已成為推動產業數位轉型與智慧化應用的核心基石。機器學習的本質，在於讓計算機系統透過統計與優化演算法，從海量的歷史數據中自動尋找潛在的規律、特徵與關聯性，進而建立具備泛化能力（Generalization Ability）的數學模型，用以預測未來或輔助複雜決策。

從理論架構上分類，機器學習主要包含三大範式：**監督式學習（Supervised Learning）**，其數據集包含明確的標籤，旨在建立特徵與目標之間的映射關係；**非監督式學習（Unsupervised Learning）**，處理無標籤數據，側重於發掘數據內部的架構與分佈特徵；以及**增強學習（Reinforcement Learning）**，強調代理人在動態環境中透過試錯與獎勵機制最大化長期收益。本研讀報告將針對業界最主流、應用最廣泛的「十大核心機器學習演算法」進行全方位的深度剖析，從數學基礎、運作流程、細部圖解到實務案例，建構完整的技術圖譜。

2. 第一部分：監督式學習 - 回歸模型

1. 線性回歸 (Linear Regression)

線性回歸是統計學與機器學習中最基礎且歷史悠久的回歸演算法。其核心目標是建構一個或多個自變數（Independent Variables）與一個因變數（Dependent Variable）之間的線性特徵映射關係。當自變數僅有一個時稱為簡單線性回歸，多個時則稱為多元線性回歸。




圖 1：線性回歸之最小平方方法擬合示意圖

在數學表達上，多元線性回歸的假設函式（Hypothesis）定義如下：

$$Y = w_1X_1 + w_2X_2 + \dots + w_nX_n + b$$

其中， $\mathbf{Y}$ 為預測目標， $\mathbf{x}_i$ 為輸入特徵， $\mathbf{w}_i$ 為演算法需要學習的權重係數 (Weights)， b 為截距或偏置 (Bias)。為了尋找最佳的權重參數，線性回歸通常採用最小平方方法 (Ordinary Least Squares, OLS)，透過最小化殘差平方和 (Residual Sum of Squares, RSS) 作為損失函數：

$$Loss(\mathbf{w}, b) = \sum (Y_i - \hat{Y}_i)^2$$

在實務工程中，若特徵維度極高或存在共線性，通常會加入正規化項以防止模型過擬合 (Overfitting)，進而衍生出 Ridge 回歸 (L2 正規化) 與 Lasso 回歸 (L1 正規化)。

實務案例：企業房屋資產價值預估

場景說明：某不動產投資企業希望透過歷史交易數據，自動預估特定新進物件的市場合理總價。

特徵輸入：坪數 (X_1)、屋齡 (X_2)、捷運站距離 (X_3)。

演算成效：透過最小平方方法迭代優化，模型得出公式： $\mathbf{Y} = 55\mathbf{X}_1 - 2.3\mathbf{X}_2 - 15\mathbf{X}_3 + 120$ 。透過此公式，可於毫秒內針對新物件產出高精準度的基礎定價參考值。

3. 第二部分：監督式學習 - 分類模型

2. 邏輯回歸 (Logistic Regression)

儘管名稱中帶有「回歸」，邏輯回歸在實務上卻是極為經典且廣泛應用的二元分類（Binary Classification）演算法。其核心思想是在線性回歸的基礎之上，將線性預測值轉化為概率輸出。




圖 2：邏輯回歸 Sigmoid 激活函數與分類閾值映射圖

邏輯回歸利用了 **Sigmoid 函數**（又稱乙狀函數）將任意實數映射到 $(0, 1)$ 區間內，該數值可直接解讀為事件發生的機率：

$$P(Y=1|X) = \sigma(z) = 1 / (1 + e^{-z})$$

其中 $z = w^T X + b$

其損失函數採用**交叉熵損失（Cross-Entropy Loss）**或稱對數損失。當模型輸出的機率大於 0.5 時，我們將樣本分類為正類（1），反之則分類為負類（0）。邏輯回歸運算速度極快、可解釋性極高，是金融風控與電商點擊率預測的黃金標準。

實務案例：金融機構信貸風險審查系統

場景說明：銀行需要針對信用卡或貸款申請者，即時評估其是否會發生違約（Default）。

數據特徵：信用評分、年收入、負債比率、歷史延遲繳款次數。

實務效果：系統藉由邏輯回歸計算出每位申請人的違約機率。若預估機率達 0.65（高於 0.5 閾值），系統將自動觸發人工照會或直接婉拒貸款，大幅降低呆帳率。

3. 支持向量機 (Support Vector Machines, SVM)

支持向量機 (SVM) 是一種極為強大且優雅的監督式學習演算法，主要用於解決高維空間中的複雜分類問題。其核心目標是在特徵空間中尋找一個**最佳超平面 (Optimal Hyperplane)**，將不同類別的數據點完全分隔開來，並使分隔邊界 (Margin) 達到最大化。




圖 3：支持向量機之最佳超平面與支持向量示意圖

SVM 理論中的「支持向量」指的是那些最靠近超平面、決定了邊界寬度的臨界數據點。對於非線性可分 (Non-linearly Separable) 的真實數據，SVM 引入了 **核技巧 (Kernel Trick)**，如徑向基函數 (RBF) 核。核技巧的核心在於將低維特徵空間隱式地映射到高維特徵空間，在低維空間看來錯綜複雜的非線性邊界，在高維空間中便可透過一個線性超平面完美劃分。

實務案例：醫療診斷中的腫瘤良惡性辨識

場景說明：基於病理切片檢驗數據，輔助醫師判斷細胞屬於良性 (Benign) 或惡性 (Malignant)。

特徵輸入：腫瘤厚度、細胞大小均勻度、邊緣黏附力等十餘項生理指標。

演算成效：透過 RBF 核函數之 SVM 進行訓練，能精準劃分複雜的跨期生理病變特徵，其臨床分類準確度高達 97% 以上。

4. 單純貝氏分類器 (Naive Bayes Classifier)

單純貝氏分類器是一組基於貝氏定理 (Bayes' Theorem) 的機器學習分類演算法。之所以被稱為「單純 (Naive)」，是因為它有一個極度大膽且強烈的假設：所有輸入特徵在給定輸出類別的前提下，彼此之間完全獨立。



圖 4：單純貝氏之經典概率理論架構圖

儘管特徵獨立性假設在現實世界中鮮少完全成立，單純貝氏分類器在實際應用中的表現卻驚人地優秀，尤其擅長處理高維度的文字數據。在數學上，分類決策公式如下：

$$\hat{Y} = \underset{k}{\operatorname{argmax}} P(C_k) \prod P(X_i | C_k)$$

由於不需要計算複雜的特徵組合權重，單純貝氏僅需簡單的計數與頻率統計即可完成訓練，因此面對巨量數據時，其運算極具優勢，且不易過擬合。

實務案例：電子郵件伺服器之垃圾郵件 (Spam) 即時過濾

場景說明：電子郵件系統需在接收郵件的瞬間，判定其為一般郵件或垃圾廣告信。

特徵抽取：郵件中各個獨立詞彙（如「發票」、「免費」、「中獎」、「提款」）出現的頻率。

演算成效：即使一封郵件包含上千個單字，單純貝氏模型也能透過詞頻乘積迅速算出機率，在幾毫秒內將廣告垃圾郵件自動歸類至垃圾桶。

5. K-最近鄰演算法 (K-Nearest Neighbors, KNN)

K-最近鄰演算法 (KNN) 是機器學習中最直觀的非參數化 (Non-parametric) 方法。它屬於消極學習 (Lazy Learning)，這意味著它在訓練階段幾乎不需要進行任何實質的數學計算，而是直接將所有訓練數據存儲起來，直到面對測試樣本時才進行即時運算。



圖 5：KNN 演算法多數決機制與空間距離劃分示意圖

當一個全新樣本輸入時，KNN 的運作步驟極為單純：首先計算該點與特徵空間中所有訓練樣本的距離（如歐式距離 **Euclidean Distance**），接著找出距離最近的 K 個鄰居，最後讓這 K 個鄰居進行投票，票數最多的類別即為該新樣本的預測分類。KNN 的效能高度依賴於 K 值的選擇與距離度量方法的設計。

實務案例：電商平台的相似用戶群體劃分與基本推薦系統

場景說明： 當一位新註冊用戶瀏覽商品時，平台希望迅速找出與其消費行為最貼近的群體以投放初始推薦。

數據指標： 用戶年齡、瀏覽偏好特徵向量、停留時間。

實務效果： 設定 $K=5$ ，系統在多維空間中瞬間撈出與該新用戶距離最近的 5 位既有老客戶，並直接將這 5 位老客戶共同喜愛的商品精準推薦給新用戶。

4. 第三部分：樹狀模型與整合式學習

6. 決策樹 (Decision Trees)

決策樹是一種模擬人類決策機制的層級式結構模型。它從一個根節點（Root Node）開始，根據特徵屬性的評估條件向下分支出子節點，最終導向葉節點（Leaf Node），每個葉節點代表一個最終的預測類別或數值。




圖 6：決策樹結構分枝與層級分支邏輯圖

建構決策樹的核心關鍵在於「如何在中繼節點選擇最佳的分裂特徵」。常見的經典演算法如 ID3、C4.5 與 CART，分別採用了 **資訊增益 (Information Gain)**、**資訊增益比 (Gain Ratio)** 以及 **吉尼不純度 (Gini Impurity)**。其背後的數學本質是希望每次分裂後，子節點內數據的混亂程度（熵）降到最低，使各子集合的純度（Purity）最大化。決策樹最大的優勢是具備完美的視覺可讀性與白盒（White-box）特性。

實務案例：電信營運商之流失客戶（Churn）特徵辨識

場景說明：辨識哪些合約即將到期的客戶具有高度退租風險，以便提前實施行銷挽留措施。

分支規則：根節點首先判斷「過去三個月通話量是否下降超過 50%」，若是則進一步判斷「客服投訴次數是否大於 2 次」。

營運價值：產出的樹狀圖結構可直接轉化為前線業務人員的具體話術操作指引，跨部門溝通毫無障礙。

7. 隨機森林 (Random Forest)

單一決策樹極易產生過擬合且結構不穩定。為了解決這個通病，**隨機森林 (Random Forest)** 應運而生。隨機森林是**整合學習 (Ensemble Learning)** 中 Bagging 架構的集大成者，透過建構大量獨立決策樹組成的「森林」來共同承擔風險。




圖 7：隨機森林子模型整合並行投票決策機制圖

隨機森林的核心引入了雙重隨機性：第一是**樣本隨機性**，利用 Bootstrap 方法從原始數據集中有放回地隨機抽取不同的子樣本集；第二是**特徵隨機性**，在樹的每個節點分裂時，僅隨機挑選一部分特徵進行評估。這雙重隨機性使得各棵決策樹之間的相關性降到最低。最終，分類任務採用**多數決投票 (Majority Voting)**，回歸任務則採用均值輸出。這使其具備極強的抗噪能力與無與倫比的泛化穩定性。

實務案例：電商平台之信用卡異常刷卡與詐欺檢測 (Fraud Detection)

場景說明：每秒數萬筆的線上金流交易，必須在 50 毫秒內攔截可能被盜刷的偽冒交易。

面臨挑戰：異常交易樣本極其稀少且手法多變，單一模型容易漏報或誤報。

實務成效：隨機森林動用數百棵隨機特徵樹同步判定，即使詐欺犯刻意避開了某些傳統敏感指標，多維度的森林投票仍能精準攔截異常，將企業金流損失降至極低。

8. 梯度提升架構 (Gradient Boosting Models)

如果說隨機森林是並行群體作戰，那麼梯度提升模型（如 XGBoost、LightGBM、CatBoost）則是串行迭代的頂尖高手。它屬於整合學習中的 **Boosting** 範式。




圖 8：梯度提升（*Gradient Boosting*）串行迭代與殘差修正邏輯架構圖

與隨機森林同時獨立建樹不同，梯度提升模型是**一步一步、循序漸進**建構決策樹的。每一棵新加入的樹，其核心任務都不是去擬合原始的目標標籤，而是去擬合前一輪所有樹組合起來之後所產生的**殘差（Residuals）**。從數學的角度來看，這相當於在函數空間中利用**梯度下降法（Gradient Descent）**來最小化整體的損失函數。由於 XGBoost 等模型加入了二階泰勒展開優化與嚴格的權重懲罰項，它在結構化表格數據的建模表現上達到了傳統機器學習的巔峰。

實務案例：大數據競賽與高頻計量交易中的資產價格預測

場景說明： 量化投資機構利用歷史盤面分筆數據（Tick Data），預測未來數分鐘內股指期貨的絕對收益率。

演算優勢： 表格數據具有高度複雜的非線性與噪聲。XGBoost 框架透過極為強悍的串行優化，能夠在不放過任何微小殘差信號的前提下，建構出極致敏銳的強預測器，是當前量化投資與大數據競賽的常勝軍。

5. 第四部分：非監督式學習

9. K-Means 分群演算法 (K-Means Clustering)

K-Means 是最為經典且歷史悠久的非監督式學習演算法。其核心目的極為純粹：在完全沒有任何先驗標籤的情況下，自動將一組高維數據點劃分為 K 個具有高內聚性、低耦合性的聚類（Clusters）。




圖 9：K-Means 演算法質心迭代收斂與數據分群分佈圖

K-Means 的運算邏輯包含兩個交替進行的迭代步驟：第一步為 **分配 (Assignment)**，計算每個數據點到所有 K 個初始質心 (Centroids) 的空間距離，並將其指派給距離最近的質心所屬的集群；第二步為 **更新 (Update)**，重新計算每個集群內所有數據點的幾何中心 (均值)，並將其設為全新質心。這兩個步驟不斷重複，直到質心位置不再發生顯著變更 (收斂) 為止。其實務效果通常搭配「肘部法 (Elbow Method)」來尋找最佳的 K 值。

實務案例：零售與電商巨頭之客戶精細化分群行銷 (Customer Segmentation)

場景說明： 企業希望從數百萬名會員中，自動辨識出具備相似消費特徵的客群，以便制定差異化的促銷策略。

數據維度： 購買頻次、客單價、商品品類偏好。偏好特徵經歸一化後輸入 K-Means。

實務產出： 模型成功切分出三類核心客群：高客單低頻次的「潛在VIP族群」、高頻次低客單的「精打細算族群」以及穩定消費的「核心中產族群」，助攻行銷團隊實現精準打擊。

10. 主成分分析 (Principal Component Analysis, PCA)

在大數據時代，數據特徵往往動輒成百上千維，這不僅帶來了沉重的計算負擔，更會引發災難性的「維度詛咒 (Curse of Dimensionality)」。**主成分分析 (PCA)** 正是破解這一困局的王牌演算法，其本質是一種非監督式的線性**維度縮減 (Dimensionality Reduction)** 技術。




圖 10：PCA 主成分投影特徵變換與最大方差捕捉示意圖

PCA 的核心幾何思想是：尋找一個全新的正交坐標系，將原始數據投影到新坐標軸上。在選擇第一個新坐標軸（第一主成分，PC1）時，要求原始數據在該軸上的**投影方差達到最大化**（即保留最多的原始訊息）；第二主成分（PC2）則必須與 PC1 完全正交，且捕捉剩餘方差中最大的部分。在數學實現上，PCA 透過計算數據特徵的協方差矩陣（Covariance Matrix），進行特徵值分解（Eigenvalue Decomposition）或奇異值分解（SVD），萃取出前 d 個特徵向量來重構低維數據空間。

實務案例：高維度晶片測試數據的特徵降維與故障模式視覺化

場景說明： 半導體製造程序中，晶片測試機台在出廠前會產生多達 500 個物理與電氣參數特徵，研發工程師難以直接在高維空間中觀測異常分佈。

解決方案： 導入 PCA 演算法，將 500 維的測試特徵高度壓縮至方差保留高達 90% 的 2 維主成分（PC1 與 PC2）。工程師隨後將這 2 個維度繪製成二維平面散點圖，便能一眼識破製程設備的潛在故障群聚偏離，大幅提升產品良率。

6. 第五部分：演算法核心效能與適用場景綜合評估

綜上所述，機器學習領域並不存在某個能完美碾壓所有場景的「萬能神級演算法」，此一基礎科學定理在學術界被稱為「**沒有免費的午餐定理**」（**No Free Lunch Theorem**）。在實際的架構設計與數據工程實務中，資深工程師的核心價值，正在於能夠根據具體的商務需求、數據集的規模大小、特徵的維度密度、模型的可解釋性要求，以及線上系統的運算時延（Latency）限制，從而挑選出最妥適、最穩健的演算法組合。為了建立直觀的架構對照，特將上述十大核心演算法之關鍵指標彙整如下表：

演算法名稱	學習範式分類	計算複雜度	模型可解釋性	對異常值敏感度	最佳核心應用場景
1. 線性回歸	監督式 (回歸)	低 (極快)	極高 (白盒)	高度敏感	連續數值預測、財務營收趨勢預估
2. 邏輯回歸	監督式 (分類)	低 (極快)	極高 (白盒)	中度敏感	金融信用風險審查、電商點擊率預測
3. 支持向量機	監督式 (分類/回歸)	中至高 (依核函數)	較低 (黑盒傾向)	低 (取決於支持向量)	複雜高維特徵生化檢驗、文本精準分類
4. 單純貝氏	監督式 (分類)	極低 (計數運算)	高 (概率明確)	極低 (抗噪能力強)	巨量文本垃圾郵件過濾、輿情情感分析
5. K-最近鄰	監督式 (分類/回歸)	高 (線上即時全量計算)	高 (鄰居直觀)	高度敏感	中小型數據集快速比對、基礎冷啟動推薦
6. 決策樹	監督式 (雙能)	低	極高 (樹狀圖白盒)	低	企業營運策略樹狀分支、客戶流失規則萃取
7. 隨機森林	監督式 (整合型)	中高 (多樹並行)	中度 (可輸出特徵重要性)	極低 (抗噪能力完美)	高穩定度金融異常盜刷攔截、多變特徵分類
8. 梯度提升樹	監督式 (整合型)	高 (串行疊代)	中度 (可輸出特徵重要性)	低	Kaggle大數據競賽、高頻量化投資與精準預測
9. K-Means	非監督式 (分群)	中度 (依迭代次數)	高 (質心幾何直觀)	高度敏感 (拉動質心)	海量會員群體畫像切分、市場精細化行銷
10. 主成分分析	非監督式 (降維)	中高 (矩陣奇異值分解)	低 (新特徵為線性組合)	高度敏感 (需預先標準化)	高維度巨量特徵壓縮降維、製程觀測視覺化

這份詳盡的模型技術圖譜，為數據科學工程團隊提供了兼具理論深度與實務厚度的決策指引。在生成式人工智慧與大型語言模型百花齊放的全新紀元裡，這十大核心經典機器學習演算法，依然以其極高的計算效率、低廉的算力成本、卓越的穩健性以及無可替代的可解釋性優勢，在工業界的第一線生產環境中散發著璀璨的技術光芒。